

Approssimazione di Basso Rango e Completamento di Matrici Sparse

Un Sistema di Raccomandazione tramite Matrix Factorization

Marco Gionfriddo

Matr. 1000084711

Numerical Methods for Scientific Computing



Università
di Catania

Il problema

Predire i rating che gli utenti darebbero ai film che non hanno ancora visto.

Formalmente: una matrice utenti $\times$ film


$$R \in \mathbb{R}^{n_u \times n_i}$$

osservata solo su $\Omega \subset \{1, \dots, n_u\} \times \{1, \dots, n_i\}$.

Dataset **MovieLens ml-latest-small**:

- 610 utenti, 9 724 film
- 100 836 rating osservati (scala da 0.5 a 5.0)
- densità $\approx 1,7\%$

Idea guida: cercare una **struttura di basso rango** nella matrice.



$\approx 1,7\%$ osservato

Il resto è ignoto — non zero.

Baseline: la media globale

Come valutiamo. I voti osservati sono divisi in **80% training** (per costruire il modello) e **20% test** (per misurarlo). L'errore è sempre calcolato sul test: voti reali che il modello non vede in addestramento.

Il predittore più semplice possibile assegna a ogni coppia (u, i) la media globale dei voti:

$$\text{RMSE} = \sqrt{\frac{1}{|\mathcal{T}|} \sum_{(u,i) \in \mathcal{T}} (r_{ui} - \mu)^2} = \mathbf{1,05}, \quad \mu = \frac{1}{|\Omega_{\text{train}}|} \sum_{(u,i) \in \Omega_{\text{train}}} r_{ui} \approx 3,50.$$

Il riferimento

Qualunque metodo più sofisticato deve battere questo valore.

Altrimenti la sua complessità non è giustificata.

SVD ed Eckart–Young: il tentativo che fallisce

Teorema (Eckart–Young). La SVD troncata $A_k = U_k \Sigma_k V_k^T$ è la *migliore* approssimazione di rango $\leq k$:

$$\|A - A_k\|_F \leq \|A - B\|_F \quad \forall B : \text{rank}(B) \leq k$$

L'ostacolo: la SVD richiede una matrice *completa*. La nostra è per il 98% vuota. Rimediamo riempiendo le celle mancanti — con quale valore?

Riempimento	RMSE	Media predetta
0.0	3.02	0.71
0.5 (min. scala)	2.62	1.13
$\mu \approx 3.50$	0.99	3.54
<i>baseline</i>	1.05	—

Il problema non è di scala, è di posizione: riempire con 0 dichiara falsamente che il 98% degli utenti odia il 98% dei film. La SVD è ottima per l'*approssimazione*, non per il *completamento*.

La riformulazione: minimi quadrati regolarizzati

Parametrizziamo direttamente la struttura di rango basso:

$$\hat{r}_{ui} = p_u^\top q_i, \quad P \in \mathbb{R}^{n_u \times k}, \quad Q \in \mathbb{R}^{n_i \times k}, \quad k = 20$$

e minimizziamo sulle *sole celle osservate*:

$$\min_{P, Q} \underbrace{\sum_{(u,i) \in \Omega} (r_{ui} - p_u^\top q_i)^2}_{\text{errore sulle osservazioni}} + \underbrace{\lambda(\|P\|_F^2 + \|Q\|_F^2)}_{\text{regolarizzazione (Tikhonov)}}$$

- La somma è ristretta a Ω : le celle non osservate non introducono bias.
- Il termine $\lambda(\|P\|_F^2 + \|Q\|_F^2)$ stabilizza il problema e controlla l'overfitting.
- **Non convesso**: non c'è soluzione chiusa. Servono metodi iterativi.

Il numero di fattori latenti $k = 20$ è fissato a un valore tipico della letteratura; lo stesso k è usato anche per la SVD troncata, così i due approcci sono confrontati a parità di rango.

Due metodi del gradiente: SGD e ADAM

SGD — passo fisso η

Per ogni osservazione (u, i, r_{ui}) :

$$e_{ui} = r_{ui} - p_u^\top q_i$$

$$p_u \leftarrow p_u + \eta(e_{ui} q_i - \lambda p_u)$$

$$q_i \leftarrow q_i + \eta(e_{ui} p_u - \lambda q_i)$$

Semplice, veloce, molto sensibile alla scelta di η .

ADAM — passo adattivo per coordinata

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$$


$$\hat{m}_t = m_t / (1 - \beta_1^t), \quad \hat{v}_t = v_t / (1 - \beta_2^t)$$

$$\theta_t = \theta_{t-1} - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \varepsilon}$$

Momento primo e secondo del gradiente. Passo riscaldato automaticamente.

Domanda numerica: quale si comporta meglio, e in che senso?

Sensibilità al passo: SGD vs ADAM



Al passo ottimo ($\eta = 0,02$):

- SGD: RMSE 0,90
- ADAM: RMSE 0,93

Su tutto l'intervallo di η :

- ADAM stabile
- SGD degrada o diverge fuori dalla banda ottima

Non c'è un vincitore assoluto.
È un compromesso
velocità vs robustezza.

Riepilogo: il percorso in una tabella

Metodo	RMSE (test warm)
Media globale (baseline)	1,045
SVD troncata, zero-fill	3,005
SVD troncata, mean-fill	0,994
Matrix Factorization – ADAM	0,930
Matrix Factorization – SGD	0,899

- La SVD ingenua è *peggio* della baseline: ricostruisce l'artefatto del riempimento.
- Solo formulando il problema *sulle sole osservazioni* si ottiene un miglioramento sostanziale.
- Fra SGD e ADAM la differenza in RMSE è modesta; la differenza in *robustezza* è la lezione.

Test warm: i voti di test relativi a film presenti anche in training (il $\sim 96\%$). Il restante 4% riguarda film mai visti in training, per cui nessun modello a fattori latenti può stimare un vettore.

Il modello all'opera: raccomandazioni

Utente 414 — voti 5.0:

- American Beauty
dramma, 1999
- American Graffiti
commedia, anni '70
- The Princess Bride
avventura, anni '80

Raccomandazioni del modello:

- The Philadelphia Story
commedia, anni '40
- The Big Sleep
noir, anni '40
- Guess Who's Coming. . .
dramma, anni '60

Stesso profilo di gusto — cinema classico d'autore — senza che al modello sia mai stato detto cosa sia un “genere”.

Conferma: similarità tra film

Chiedendo i film più simili a **Toy Story**, il modello restituisce altri film d'animazione per famiglie. La struttura semantica emerge dai soli voti.

Limiti onestamente riconosciuti

- Valutazione con RMSE, non con metriche di ranking (precision@k, NDCG).
- Split casuale invece che temporale.
- Nessuno studio sistematico su k e λ .

Estensioni naturali

- Bias per utente e per item: $\hat{r}_{ui} = \mu + b_u + b_i + p_u^\top q_i$.
- Confronto con **Alternating Least Squares**.
- Split temporale e metriche di ranking.

Grazie per l'attenzione.

Marco Gionfriddo