



Università
di Catania

DIPARTIMENTO DI MATEMATICA E INFORMATICA
CORSO DI LAUREA MAGISTRALE IN INFORMATICA

Marco Gionfriddo

Approssimazione di Basso Rango e Completamento di Matrici
Sparse: un Sistema di Raccomandazione tramite Matrix
Factorization

TESINA FINALE
NUMERICAL METHODS FOR
SCIENTIFIC COMPUTING

Prof. Sebastiano Boscarino

Anno Accademico 2025 - 2026

Indice

Introduzione	1
1 Fondamenti teorici	3
1.1 Il Problema: Completamento di una Matrice Sparsa	3
1.2 SVD e Teorema di Eckart–Young	4
1.3 Matrix Factorization come Minimi Quadrati Regolarizzati . .	5
1.4 Metodi del Gradiente: SGD e ADAM	6
2 Metodo, Esperimenti e Risultati	8
2.1 Baseline: la Media Globale	9
2.2 SVD Ingenua e il Problema del Riempimento	10
2.3 Matrix Factorization Addestrata con SGD	11
2.4 SGD vs ADAM	12
2.5 Raccomandazioni e Film Simili	14
2.6 Quadro Riepilogativo	15
3 Conclusioni	16
3.1 Sintesi dei Risultati	16
3.2 Limiti del Lavoro	17
3.3 Sviluppi Futuri	18

Introduzione

I sistemi di raccomandazione sono uno degli esempi più diffusi e riconoscibili di come metodi di calcolo numerico si traducano in applicazioni pratiche di uso quotidiano. Ogni volta che una piattaforma di streaming propone un film, un negozio online un prodotto o un servizio musicale un brano, ciò che si vede in superficie è il risultato di un processo di stima: predire, per un dato utente, quanto gradirebbe un item che non ha ancora provato. Il problema, apparentemente elementare, poggia su un impianto matematico consolidato – algebra lineare numerica, approssimazione di matrici, ottimizzazione – ed è quindi particolarmente adatto a un progetto di Calcolo Numerico che voglia mettere in luce il legame fra teoria e applicazione.

L’obiettivo di questa tesina è progettare, implementare e analizzare un sistema di raccomandazione basato su **matrix factorization** a basso rango, addestrato con metodi del gradiente, e discutere in modo critico i risultati ottenuti. Il dominio applicativo è quello classico dei rating di film: si utilizza il dataset MovieLens `ml-latest-small`, con circa 100 000 valutazioni espresse da 610 utenti su 9 724 film.

Sul piano numerico il progetto si articola intorno a tre nuclei del programma del corso. Il primo è la **Decomposizione ai Valori Singolari**, che insieme al Teorema di Eckart–Young fornisce il quadro teorico dell’approssimazione ottima di basso rango di una matrice, e che discuteremo sia come strumento di riferimento sia mettendo in evidenza i suoi limiti nel contesto di una matrice largamente incompleta. Il secondo è la formulazione del problema come sistema di **minimi quadrati regolarizzati** sull’insieme delle sole osservazioni disponibili – una scelta che nasce direttamente dal fallimento della SVD applicata in modo ingenuo e che porta a una funzione obiettivo non convessa. Il terzo sono i **metodi del gradiente stocastico**: implementeremo e confronteremo Stochastic Gradient Descent (SGD) e ADAM, con particolare attenzione al comportamento di convergenza e alla sensibilità al passo di apprendimento, un tema centrale nell’analisi numerica degli algoritmi iterativi.

Il filo conduttore del lavoro è la scelta di procedere per confronti espliciti e

verificabili. Ogni metodo introdotto viene misurato rispetto a un riferimento più semplice sulla stessa metrica di errore (RMSE su un test set), in modo che ogni passaggio – dalla baseline elementare al modello finale – sia giustificato da un miglioramento quantitativo e non da un’assunzione. Nel farlo emergeranno anche i limiti dei singoli approcci: perché una SVD ingenua può essere addirittura controproducente rispetto a predire la media; perché il metodo teoricamente ottimo per l’approssimazione di basso rango non è il metodo ottimo per il completamento di matrice; perché fra due ottimizzatori non ce n’è uno migliore in assoluto, ma esistono compromessi diversi tra velocità e robustezza.

Il documento è organizzato come segue. Il Capitolo 1 raccoglie gli strumenti teorici necessari: il problema del completamento di matrice, la SVD e il Teorema di Eckart–Young, la formulazione della matrix factorization come minimi quadrati regolarizzati, e i metodi SGD e ADAM. Il Capitolo 2 descrive il dataset, la metodologia di valutazione, e presenta gli esperimenti nell’ordine in cui si sviluppa il ragionamento numerico: baseline, SVD ingenua, matrix factorization, confronto fra SGD e ADAM, e una verifica qualitativa del modello sulla generazione di raccomandazioni. Le conclusioni sintetizzano i risultati e delineano alcune direzioni di sviluppo naturali.

Capitolo 1

Fondamenti teorici

Questo capitolo raccoglie gli strumenti di calcolo numerico che useremo nel Capitolo 2. Le quattro sezioni seguono l'ordine logico del progetto: si parte dalla formalizzazione del problema (Sezione 1.1), si introduce la Decomposizione ai Valori Singolari e il teorema di Eckart–Young come risultato di ottimalità per l'approssimazione di basso rango (Sezione 1.2), si mostra perché la SVD chiusa non è adatta al nostro problema e si formula la matrix factorization come minimi quadrati regolarizzati (Sezione 1.3), e si descrivono infine i due metodi del gradiente che useremo per risolverla, SGD e ADAM (Sezione 1.4).

1.1 Il Problema: Completamento di una Matrice Sparsa

Consideriamo n_u utenti e n_i item (nel nostro caso, film) e organizziamo i rating in una matrice $R \in \mathbb{R}^{n_u \times n_i}$ in cui l'elemento r_{ui} è la valutazione data dall'utente u al film i . In pratica gli utenti valutano soltanto una piccola frazione dei film disponibili, e R è osservata solo su un sottoinsieme $\Omega \subset \{1, \dots, n_u\} \times \{1, \dots, n_i\}$: le altre celle non sono nulle, sono *mancaanti*.

Il problema è quindi di **completamento di matrice**: dato $\{r_{ui} : (u, i) \in \Omega\}$, si vuole stimare $\hat{r}_{ui}$ per $(u, i) \notin \Omega$. Come vedremo, il problema è ben posto solo se si assume che R abbia una struttura sottostante semplice; l'ipotesi che useremo è che R sia ben approssimata da una matrice di basso rango.

Osservazione 1.1 (Perché basso rango è ragionevole) *L'assunzione ha una lettura intuitiva: se un piccolo numero di “fattori latenti” (per esempio il gradimento verso certi generi, epoche, registi) riassume adeguatamente il*

gusto di ogni utente e le caratteristiche di ogni film, allora ciascun rating è approssimabile come combinazione di questi fattori, e R è di fatto una matrice di basso rango perturbata da rumore. È un'ipotesi non dimostrabile a priori, ma verificata a posteriori dalla qualità delle predizioni.

1.2 SVD e Teorema di Eckart–Young

Sia $A \in \mathbb{R}^{m \times n}$ una matrice qualsiasi, con $m \geq n$ (l'ipotesi non è restrittiva). La sua **Decomposizione ai Valori Singolari** (SVD) è la fattorizzazione

$$A = U \Sigma V^\top, \quad (1.1)$$

dove $U \in \mathbb{R}^{m \times m}$ e $V \in \mathbb{R}^{n \times n}$ sono ortogonali e $\Sigma \in \mathbb{R}^{m \times n}$ è “diagonale” con elementi non negativi $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_n \geq 0$, detti **valori singolari** di A . La SVD esiste per ogni matrice reale (o complessa) ed è uno dei risultati centrali dell'algebra lineare numerica.

Fissato un intero $k \leq \text{rank}(A)$, la **SVD troncata** di rango k è

$$A_k = U_k \Sigma_k V_k^\top = \sum_{j=1}^k \sigma_j u_j v_j^\top, \quad (1.2)$$

dove U_k e V_k contengono le prime k colonne di U e V , e Σ_k è il blocco superiore sinistro $k \times k$ di Σ . Per costruzione, A_k è di rango al più k . La sua importanza è chiarita dal seguente teorema.

Proposizione 1.1 (Eckart–Young) *Sia $A \in \mathbb{R}^{m \times n}$ e sia A_k la sua SVD troncata di rango k definita dalla (1.2). Allora A_k è la migliore approssimazione di A tra le matrici di rango al più k , sia in norma di Frobenius che in norma spettrale: per ogni $B \in \mathbb{R}^{m \times n}$ con $\text{rank}(B) \leq k$,*

$$\|A - A_k\|_F \leq \|A - B\|_F, \quad \|A - A_k\|_2 \leq \|A - B\|_2, \quad (1.3)$$

e vale l'espressione esplicita per l'errore

$$\|A - A_k\|_F^2 = \sum_{j=k+1}^{\min(m,n)} \sigma_j^2, \quad \|A - A_k\|_2 = \sigma_{k+1}. \quad (1.4)$$

Il teorema di Eckart–Young è la giustificazione teorica dell'uso della SVD troncata come strumento di approssimazione di basso rango: nessun altro metodo può fare meglio in norma di Frobenius o spettrale.

Osservazione 1.2 (Il limite pratico per il nostro problema) *Il teorema si applica a A completa. Nel nostro caso R è nota solo sulle celle di Ω : per usare direttamente la SVD dovremmo prima riempire le celle mancanti con qualche valore, ma allora A_k non minimizza più l'errore sulle sole celle osservate – minimizza l'errore su una matrice inventata al 98%. Il Capitolo 2 mostrerà sperimentalmente quanto questo sia dannoso.*

1.3 Matrix Factorization come Minimi Quadrati Regolarizzati

La conclusione naturale è che l'obiettivo non deve essere formulato su *tutta* la matrice, ma solo sulle celle effettivamente osservate. Parametizziamo direttamente l'approssimazione di rango k : cerchiamo due matrici di **fattori latenti**

$$P \in \mathbb{R}^{n_u \times k}, \quad Q \in \mathbb{R}^{n_i \times k}, \quad (1.5)$$

tali che il rating dell'utente u sul film i sia approssimato dal prodotto scalare dei rispettivi vettori:

$$\hat{r}_{ui} = p_u^\top q_i, \quad (1.6)$$

dove $p_u^\top$ e $q_i^\top$ sono la u -esima riga di P e la i -esima riga di Q . La ricostruzione complessiva $\hat{R} = PQ^\top$ ha rango al più k per costruzione.

Il problema di stima si formula come **minimi quadrati sulle sole osservazioni**, con un termine di regolarizzazione di Tikhonov:

$$\min_{P, Q} \mathcal{L}(P, Q) = \sum_{(u, i) \in \Omega} (r_{ui} - p_u^\top q_i)^2 + \lambda (\|P\|_F^2 + \|Q\|_F^2). \quad (1.7)$$

Il termine $\lambda(\|P\|_F^2 + \|Q\|_F^2)$, con $\lambda > 0$, penalizza soluzioni con fattori di norma grande e ha due funzioni: controlla l'overfitting sulle osservazioni rumorose e migliora il condizionamento del problema, stabilizzando la stima di quei p_u o q_i per cui si hanno pochi dati.

Osservazione 1.3 (Differenze rispetto alla SVD) *La (1.7) differisce dall'approssimazione di basso rango di Eckart–Young in due aspetti sostanziali. Primo, la somma è ristretta a Ω : le celle non osservate non contribuiscono alla loss, quindi non inducono alcun bias. Secondo, il problema non ammette soluzione chiusa tramite SVD: fissando P è quadratico in Q e viceversa, ma la funzione congiunta $\mathcal{L}(P, Q)$ non è convessa (è invariante per trasformazioni $P \rightarrow PS$, $Q \rightarrow QS^{-\top}$ con S invertibile) e va risolta con metodi iterativi.*

1.4 Metodi del Gradiente: SGD e ADAM

Per risolvere la (1.7) usiamo metodi del gradiente del prim'ordine. Il gradiente della loss rispetto a una singola osservazione $(u, i, r_{ui}) \in \Omega$, definito $e_{ui} = r_{ui} - p_u^\top q_i$, è

$$\frac{\partial \mathcal{L}_{ui}}{\partial p_u} = -e_{ui} q_i + \lambda p_u, \quad \frac{\partial \mathcal{L}_{ui}}{\partial q_i} = -e_{ui} p_u + \lambda q_i. \quad (1.8)$$

Da queste espressioni derivano tutti i metodi che useremo.

Stochastic Gradient Descent (SGD)

Nella versione stocastica, invece di sommare i gradienti su tutto Ω per un singolo aggiornamento, si estrae un'osservazione (u, i, r_{ui}) alla volta e si aggiornano *solo* i due vettori coinvolti, p_u e q_i :

$$p_u \leftarrow p_u + \eta(e_{ui} q_i - \lambda p_u), \quad (1.9)$$

$$q_i \leftarrow q_i + \eta(e_{ui} p_u - \lambda q_i), \quad (1.10)$$

dove $\eta > 0$ è il **passo di apprendimento** (learning rate). Un'epoca consiste nel visitare tutte le osservazioni in Ω in ordine casuale. Il costo per osservazione è $O(k)$, e per epoca $O(k|\Omega|)$: SGD è quindi molto efficiente su dati sparsi, dove $|\Omega|$ è molto minore di $n_u \cdot n_i$.

La scelta di η è delicata: se troppo piccolo, la convergenza è lenta e può non completarsi entro il budget di epoche fissato; se troppo grande, gli aggiornamenti diventano instabili e il metodo può divergere. Questo trade-off sarà oggetto di studio sperimentale nel Capitolo 2.

ADAM

Il metodo **ADAM** (*Adaptive Moment Estimation*) generalizza SGD introducendo un passo di apprendimento *adattivo per coordinata*, basato sulle stime dei momenti primo e secondo del gradiente. Detto g_t il gradiente al passo t (calcolato come nella (1.8) per la variabile in esame), l'aggiornamento è:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t, \quad (1.11)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2, \quad (1.12)$$

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1 - \beta_2^t}, \quad (1.13)$$

$$\theta_t = \theta_{t-1} - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \varepsilon}. \quad (1.14)$$

Qui θ è la variabile aggiornata (un p_u o un q_i), g_t^2 è inteso elemento per elemento, e $\beta_1, \beta_2 \in [0, 1)$ e $\varepsilon > 0$ sono iperparametri fissati ai valori tipici $\beta_1 = 0.9$, $\beta_2 = 0.999$, $\varepsilon = 10^{-8}$.

L'idea numerica è che m_t è una media mobile esponenziale del gradiente (momento primo) e v_t una media mobile esponenziale del suo quadrato (momento secondo, non centrato). Il passo effettivo lungo ciascuna coordinata è $\eta/(\sqrt{\hat{v}_t} + \varepsilon)$: coordinate con gradiente storicamente grande vengono aggiornate con passi piccoli, coordinate con gradiente piccolo con passi grandi. La correzione del bias tramite (1.13) compensa il fatto che m_t e v_t sono inizializzati a zero e quindi sottostimati nelle prime iterazioni.

Osservazione 1.4 (Cosa aspettarsi) *Sul piano teorico ADAM introduce due caratteristiche rispetto a SGD: (i) un costo per iterazione maggiore, dovuto al mantenimento e all'aggiornamento di m_t e v_t oltre che al calcolo della radice quadrata coordinata per coordinata; (ii) una minore sensibilità alla scelta di η , perché il passo effettivo viene automaticamente riscalato in funzione dell'ordine di grandezza del gradiente. Se il primo effetto è uno svantaggio, il secondo è un vantaggio importante quando non si vuole (o non si può) fare tuning fine del passo. Il Capitolo 2 verifica entrambi questi comportamenti sui dati.*

Capitolo 2

Metodo, Esperimenti e Risultati

In questo capitolo passiamo dagli strumenti teorici del Capitolo 1 alla loro applicazione pratica su un caso concreto. Descriviamo il dataset, la metodologia di valutazione, e presentiamo gli esperimenti nell'ordine naturale in cui si sviluppa il ragionamento numerico: si parte da un riferimento elementare (la media globale), si mostra perché la SVD applicata in modo ingenuo non è sufficiente, si costruisce un modello di *matrix factorization* addestrato con metodi del gradiente, e infine se ne confrontano due varianti (SGD e ADAM) sul piano della convergenza e della robustezza al passo. Il capitolo si chiude con una verifica qualitativa del modello nella sua applicazione tipica: generare raccomandazioni personalizzate.

Dataset e Setup Sperimentale

Il dataset scelto è **MovieLens** `ml-latest-small`, un sottoinsieme del noto benchmark MovieLens distribuito da GroupLens. Contiene 100 836 valutazioni espresse da 610 utenti su 9 724 film, su una scala discreta da 0.5 a 5.0 stelle con passo 0.5. Ogni valutazione è corredata di un timestamp, che nel nostro lavoro non viene sfruttato.

La struttura del problema è quella tipica del completamento di matrice: la matrice utenti-film $R \in \mathbb{R}^{n_u \times n_i}$ con $n_u = 610$ e $n_i = 9724$ conta $n_u \cdot n_i \approx 5,93$ milioni di celle, di cui solo 100 836 sono osservate. La densità è quindi $\approx 1.7\%$: oltre il 98% della matrice è mancante, e questo aspetto sarà determinante nelle scelte metodologiche.

Split e Criterio di Valutazione

I dati sono divisi in **training set** (80%) e **test set** (20%) tramite uno split casuale con seme fissato. Per la valutazione utilizziamo la **Root Mean Squared Error** (RMSE) tra rating osservato r_{ui} e rating predetto $\hat{r}_{ui}$:

$$\text{RMSE} = \sqrt{\frac{1}{|\mathcal{T}|} \sum_{(u,i) \in \mathcal{T}} (r_{ui} - \hat{r}_{ui})^2}, \quad (2.1)$$

dove $\mathcal{T}$ è l'insieme delle coppie (u, i) del test set.

Osservazione 2.1 (Valutazione sul sottoinsieme *warm*) *Uno split puramente casuale può assegnare al test film mai visti in training, per i quali il modello non può stimare un vettore latente q_i . Nel nostro caso 813 voti di test su 20 168 (circa il 4.0%) riguardano film cold, cioè assenti dal training set. Per confrontare in modo equo i diversi metodi riportiamo l'RMSE ristretto ai voti warm. La gestione del cold start è una linea di sviluppo naturale ma esula dagli obiettivi di questa tesina.*

Scelte Implementative e Iperparametri

Il codice è scritto in Python con NumPy, pandas e scikit-learn. La dimensione dello spazio latente è fissata a $k = 20$, il passo di apprendimento a $\eta = 0.02$ e il coefficiente di regolarizzazione a $\lambda = 0.05$; l'addestramento avviene su 20 epoche. Si tratta di valori tipici nella letteratura sulla matrix factorization applicata a MovieLens; non è stato condotto uno studio di sensibilità sistematico su k e λ , mentre la sensibilità al passo di apprendimento è invece analizzata esplicitamente nella Sezione 2.4.

2.1 Baseline: la Media Globale

Il primo modello di riferimento è il più semplice possibile: predire per ogni coppia (u, i) la media globale dei rating osservati in training,

$$\hat{r}_{ui} = \mu = \frac{1}{|\Omega|} \sum_{(u,i) \in \Omega} r_{ui}. \quad (2.2)$$

Nel nostro caso $\mu \approx 3.503$. Questo predittore costante ottiene un **RMSE di 1.0488** sul test set. Non è un modello competitivo, ma costituisce un riferimento onesto: qualunque metodo più sofisticato deve migliorarlo in modo netto per giustificare la propria complessità.

2.2 SVD Ingenua e il Problema del Riempimento

Il Teorema di Eckart–Young (Capitolo 1) suggerisce di approssimare R con la sua SVD troncata di rango k . L’approccio diretto, tuttavia, si scontra con un ostacolo pratico: R ha oltre il 98% di celle mancanti, e l’algoritmo di calcolo della SVD richiede una matrice *completa*.

Un primo tentativo con `numpy.linalg.svd` applicato a una matrice contenente NaN restituisce l’errore `LinAlgError: SVD did not converge`: l’algoritmo QR iterativo su cui è basata la decomposizione non gestisce valori indefiniti.

Riempire i Mancanti

La soluzione immediata è sostituire i mancanti con un valore fissato. Abbiamo confrontato tre scelte, tenendo $k = 20$ fisso:

Tabella 2.1: Effetto del valore di riempimento sulla SVD troncata di rango $k = 20$.

Valore di riempimento	RMSE (test)	Media predetta
0.0	3.0233	0.71
0.5 (minimo della scala)	2.6213	1.13
$\mu \approx 3.503$ (media)	0.9998	3.54
<i>Baseline media globale</i>	1.0488	—

Il risultato è istruttivo. Riempire con 0 produce un RMSE quasi tre volte peggiore della baseline, e la media dei rating predetti è 0.71, molto lontana dalla media reale $\mu \approx 3.5$. Passare da 0 a 0.5 (il valore minimo effettivo della scala) migliora poco: il punto non è che 0 è fuori scala di mezza stella, ma che è lontano circa tre punti dal centro della distribuzione dei rating.

L’interpretazione è chiara alla luce di Eckart–Young: la SVD troncata è la migliore approssimazione di rango k dell’intera matrice di ingresso; non ha modo di sapere che il 98% delle celle è un artefatto. Rimpiazzare i mancanti con 0 equivale a dichiarare falsamente che gli utenti hanno dato il voto più basso possibile alla stragrande maggioranza dei film, e la ricostruzione di rango basso viene inevitabilmente trascinata verso quel valore.

Solo il riempimento con la media μ produce un RMSE (0.9998) migliore della baseline, e appena migliore: la SVD, pur essendo lo strumento teorica-

mente ottimo per l'approssimazione di basso rango, non è di per sé il metodo giusto per il problema del completamento di matrice.

Osservazione 2.2 (Verso un problema ben posto) *La conclusione naturale è che la funzione obiettivo non deve essere formulata su tutta la matrice, ma solo sulle celle effettivamente osservate. Questo porta esattamente alla formulazione della matrix factorization come problema di minimi quadrati regolarizzati, discussa nella prossima sezione.*

2.3 Matrix Factorization Addestrata con SGD

Riprendendo la formulazione del Capitolo 1, cerchiamo due matrici di fattori $P \in \mathbb{R}^{n_u \times k}$ e $Q \in \mathbb{R}^{n_i \times k}$ tali che il rating predetto sia $\hat{r}_{ui} = p_u^\top q_i$, minimizzando

$$\mathcal{L}(P, Q) = \sum_{(u,i) \in \Omega} (r_{ui} - p_u^\top q_i)^2 + \lambda(\|P\|_F^2 + \|Q\|_F^2). \quad (2.3)$$

Il problema è risolto con **Stochastic Gradient Descent**: ad ogni iterazione si estrae un'osservazione (u, i, r_{ui}) dal training set, si calcola l'errore $e_{ui} = r_{ui} - p_u^\top q_i$ e si aggiornano i soli fattori coinvolti:

$$p_u \leftarrow p_u + \eta(e_{ui} q_i - \lambda p_u), \quad (2.4)$$

$$q_i \leftarrow q_i + \eta(e_{ui} p_u - \lambda q_i). \quad (2.5)$$

Le matrici P e Q sono inizializzate con valori estratti da una gaussiana $\mathcal{N}(0, 0.1^2)$; le predizioni finali vengono *clippate* nell'intervallo $[0.5, 5.0]$ per rispettare la scala dei rating.

Risultati

L'addestramento su 20 epoche produce le curve di apprendimento in Figura 2.1: l'RMSE sul test cala in modo monotono e si stabilizza. Il valore finale è **RMSE** = 0.8992 sul test warm, un miglioramento sostanziale rispetto alla baseline (1.0488) e nettamente superiore a qualunque variante di SVD ingenua.




Figura 2.1: Andamento dell'RMSE sul test set durante l'addestramento SGD. L'RMSE scende sotto la soglia di 0.95 già alla sesta epoca e si stabilizza intorno a 0.90.

2.4 SGD vs ADAM

La domanda numerica più interessante non è quale ottimizzatore raggiunga l'RMSE più basso, ma *come* lo raggiungono. Confrontiamo SGD e ADAM (Capitolo 1) sotto due profili complementari: la velocità di convergenza a passo fissato e la sensibilità al valore del passo stesso.

Convergenza a Passo Fissato

Al passo di riferimento $\eta = 0.02$, i due metodi si comportano come riassunto in Tabella 2.2.

Tabella 2.2: Confronto SGD e ADAM a $\eta = 0.02$.

Ottimizzatore	RMSE finale	Epoche a RMSE < 0.95	Tempo relativo
SGD	0.8992	6	$\sim 1\times$
ADAM	0.9305	11	$\sim 10\times$

A questo valore di η , dunque, SGD non solo raggiunge un RMSE leggermente più basso, ma lo fa in meno epoche e a costo per epoca inferiore.

re. Sarebbe un errore, però, concludere che SGD è “il metodo migliore”: il confronto significativo emerge quando si varia il passo.

Sensibilità al Passo di Apprendimento

Ripetiamo l’addestramento facendo variare η su una griglia logaritmica. Il risultato è in Figura 2.2.




Figura 2.2: RMSE finale sul test warm in funzione del passo di apprendimento η (scala logaritmica). ADAM (curva blu) mantiene RMSE prossimo all’ottimo su un ampio intervallo di η ; SGD (curva arancione) degrada a passi piccoli per convergenza troppo lenta entro le 20 epoche a disposizione, e a passi grandi diverge.

Il quadro cambia radicalmente: ADAM produce RMSE finali di qualità simile su una finestra di η ampia circa un ordine di grandezza, mentre SGD è competitivo solo in una banda stretta intorno a $\eta = 0.02$. Fuori da quella banda, a η piccolo la convergenza è troppo lenta per essere completata entro 20 epoche (RMSE ancora alto, non è divergenza vera e propria), mentre a η grande gli aggiornamenti diventano instabili e SGD diverge.

Osservazione 2.3 (La lettura numerica) *Il compromesso che emerge è il classico compromesso velocità vs robustezza: SGD, con il passo giusto, è più rapido e leggermente più accurato, ma richiede un tuning attento del learning rate. ADAM, al contrario, adatta il passo per coordinata sfruttando*

i momenti primo e secondo del gradiente, e questo lo rende molto meno sensibile alla scelta iniziale di η al prezzo di un costo per iterazione più elevato. In un contesto in cui il tuning è costoso o non pratico, ADAM è la scelta pragmaticamente più solida.

2.5 Raccomandazioni e Film Simili

Le sezioni precedenti hanno valutato il modello in termini quantitativi (RMSE). Questa sezione conclusiva ne mostra l'utilizzo tipico e serve come *validazione qualitativa* dei fattori latenti appresi. Se P e Q codificano davvero struttura significativa, ce ne accorgeremo osservando i risultati.

Raccomandazioni per un Utente

Dato un utente u , calcoliamo il punteggio $\hat{s}_{ui} = p_u^\top q_i$ per tutti i film i non ancora visti da u , e restituiamo i primi N . Va sottolineato che $\hat{s}_{ui}$ è il prodotto scalare grezzo, non un rating calibrato: va letto come punteggio di *ranking*, non come rating predetto esatto.

Applicando la procedura all'utente 414, tra i film che aveva valutato 5.0 compaiono classici come *American Beauty* (1999), *American Graffiti* (1973) e *The Princess Bride* (1987): un profilo eterogeneo, che spazia dal dramma alla commedia di culto. I dieci film consigliati dal modello includono *Three Billboards Outside Ebbing, Missouri* (2017), *The Big Sleep* (1946), *The Philadelphia Story* (1940) e *Guess Who's Coming to Dinner* (1967): titoli plausibili come raccomandazioni per un pubblico che apprezza il cinema classico e d'autore.

Osservazione 2.4 (Un limite noto della matrix factorization) *Analizzando la lista si osserva che diversi film consigliati hanno un supporto molto basso in training (in alcuni casi meno di dieci voti). È un limite noto della matrix factorization: film votati da pochi utenti hanno un fattore latente q_i stimato su pochi dati, quindi ad alta varianza, e possono ricevere punteggi estremi anche in assenza di reale affinità con i gusti dell'utente. Il fenomeno si lega al ruolo della regolarizzazione, che stabilizza le stime proprio in questi regimi di dati scarsi.*

Similarità tra Film nello Spazio Latente

Un secondo utilizzo dei fattori appresi è la ricerca di film simili: date le rappresentazioni q_i e q_j , la similarità coseno

$$\cos(q_i, q_j) = \frac{q_i^\top q_j}{\|q_i\| \|q_j\|} \quad (2.6)$$

misura quanto due film sono “vicini” nello spazio dei gusti. Applicata a *Toy Story* (1995), la funzione restituisce come primi vicini altri film d’animazione e commedie per famiglie contemporanee, cosa attesa e rassicurante: i fattori latenti hanno catturato una struttura semantica sensata, senza che il concetto di “genere” o “pubblico target” sia stato mai fornito esplicitamente. Per contenere gli effetti di alta varianza discussi sopra, la ricerca è ristretta ai film con almeno 50 voti in training.

2.6 Quadro Riepilogativo

La Tabella 2.3 riassume gli RMSE ottenuti dai diversi metodi sul test warm.

Tabella 2.3: RMSE sul test set (warm) per i metodi considerati.

Metodo	RMSE
Media globale (baseline)	1.0488
SVD troncata, zero-fill ($k = 20$)	3.0233
SVD troncata, mean-fill ($k = 20$)	0.9998
Matrix Factorization – ADAM ($k = 20$)	0.9305
Matrix Factorization – SGD ($k = 20$)	0.8992

La progressione ha una lettura numerica coerente: la SVD applicata a una matrice riempita con 0 è controproducente perché ricostruisce fedelmente l’artefatto introdotto dal riempimento; riempire con la media riduce l’errore ma non batte in modo significativo la baseline; solo formulando il problema correttamente – minimi quadrati sulle sole osservazioni, con regolarizzazione – e risolvendolo con metodi del gradiente si ottiene un miglioramento sostanziale. La differenza fra SGD e ADAM sul singolo run è modesta; il loro diverso comportamento al variare di η è invece la lezione numerica più significativa dell’intero capitolo.

Capitolo 3

Conclusioni

Il progetto ha affrontato il problema del completamento di una matrice utenti–film sparsa attraverso una progressione di modelli di complessità crescente, mettendo a confronto in modo esplicito quattro approcci: la predizione della media globale, la SVD troncata su matrice riempita, e la matrix factorization risolta con SGD e con ADAM. Il criterio di confronto è stato uniforme – RMSE sul test warm – e i risultati principali sono riassunti nella Tabella 2.3.

3.1 Sintesi dei Risultati

Il quadro complessivo che emerge ha una lettura numerica coerente. La media globale, con RMSE 1.05, definisce il riferimento minimo che qualunque metodo più sofisticato deve battere per giustificare la propria complessità. La SVD applicata alla matrice riempita con zero fornisce un risultato istruttivo per la ragione opposta: pur essendo il metodo teoricamente ottimo per l'approssimazione di rango basso, produce un RMSE di 3.02, quasi tre volte peggiore della baseline. La spiegazione, coerente con il Teorema di Eckart–Young, è che l'ottimalità della SVD troncata è riferita all'*intera* matrice di ingresso, e nella nostra matrice più del 98% delle celle è un artefatto introdotto dal riempimento. Il rimedio non è scegliere un valore di riempimento diverso – il passaggio da 0 a 0.5 migliora poco, e persino il riempimento con la media riduce l'errore appena sotto la baseline – ma cambiare la formulazione del problema.

La matrix factorization scioglie proprio questo nodo: definire la funzione obiettivo come somma dei residui quadratici sulle sole celle osservate, aggiungendo un termine di regolarizzazione di Tikhonov. Con SGD si ottiene un RMSE di 0.90, un miglioramento sostanziale sia rispetto alla baseline

sia rispetto a qualunque variante di SVD ingenua. Il confronto con ADAM sullo stesso setup mostra una differenza modesta in RMSE finale (0.93 contro 0.90), ma il confronto significativo emerge dallo studio della sensibilità al passo di apprendimento: ADAM mantiene prestazioni stabili su un intervallo ampio di η , mentre SGD è competitivo solo in una banda stretta e degrada o diverge fuori da essa. Il messaggio numerico è che i due metodi occupano posizioni diverse nel trade-off velocità/robustezza, e la scelta fra i due dipende dal contesto in cui vengono usati.

La sezione conclusiva del Capitolo 2 ha mostrato che i fattori latenti appresi non sono soltanto uno strumento di predizione: la similarità coseno nello spazio latente produce vicinanze semantiche plausibili (film d'animazione vicini fra loro, cinema classico che raggruppa) senza che alcuna nozione di genere sia stata mai fornita esplicitamente al modello. È una validazione qualitativa del fatto che l'approssimazione di rango basso ha effettivamente catturato struttura, e non solo minimizzato una funzione obiettivo.

3.2 Limiti del Lavoro

Alcuni limiti dell'analisi vanno riconosciuti onestamente.

Il primo è la mancanza di una metrica di ranking: RMSE misura la qualità delle stime puntuali dei rating, ma un sistema di raccomandazione reale è valutato più propriamente sulla qualità della lista dei primi N item proposti (precision@ k , recall@ k , NDCG). La verifica qualitativa presentata nella Sezione 2.5 è coerente ma non quantitativa.

Il secondo è lo split casuale del test set: la scelta è metodologicamente solida per la valutazione di rating prediction e in linea con la prassi su MovieLens, ma non riproduce lo scenario applicativo tipico, in cui il sistema deve predire rating *futuri* sulla base di rating passati. Uno split temporale offrirebbe una valutazione più aderente al caso d'uso.

Il terzo è l'assenza di uno studio di sensibilità sistematico su k e λ . I valori usati sono ragionevoli e coerenti con la letteratura, ma non ottimizzati: è plausibile che uno studio più fine consenta di guadagnare qualche centesimo di RMSE.

Il quarto è il fenomeno osservato di raccomandazioni sbilanciate verso film con pochi voti in training, discusso nella Sezione 2.5. È un limite noto della matrix factorization pura, legato all'alta varianza di stima dei fattori q_i per item a basso supporto, e si affronta in letteratura o con regolarizzazioni differenziate o con l'aggiunta di termini di *bias* per utente e per item.

3.3 Sviluppi Futuri

Diverse estensioni naturali si offrono come continuazione del lavoro, ciascuna delle quali tocca temi rilevanti del calcolo numerico.

L'estensione più immediata è l'introduzione di **bias per utente e per item** nel modello, cioè $\hat{r}_{ui} = \mu + b_u + b_i + p_u^\top q_i$: è noto in letteratura che questa piccola modifica migliora sensibilmente le prestazioni su MovieLens e mitiga il problema degli item a basso supporto, senza cambiare la struttura algoritmica.

Sul piano metodologico, uno studio di sensibilità sistematico su k e λ tramite cross validation permetterebbe di quantificare in modo rigoroso l'impatto delle scelte iperparametriche e di illustrare concretamente il ruolo della regolarizzazione nel bias-variance trade-off.

Sul piano numerico, un confronto con un metodo di ottimizzazione alternativo – ad esempio **Alternating Least Squares** (ALS), che sfrutta la biconvessità di $\mathcal{L}$ risolvendo alternativamente due sistemi di minimi quadrati in forma chiusa – consentirebbe di mettere a paragone un approccio del prim'ordine con uno del second'ordine (per blocco), evidenziando trade-off diversi fra costo per iterazione e velocità di convergenza.

Infine, l'adozione di uno split temporale e l'aggiunta di metriche di ranking come $\text{precision}@k$ trasformerebbero la valutazione da diagnostica qualitativa a valutazione quantitativa applicativa, completando il ponte fra strumento numerico e sistema di raccomandazione reale.